

NLP: Lab 2.

Bài 1: Unigram

1. Vocab = { the, cat, eat, fish, like, dog, meet }

2. Mỗi câu có 4 tokens $\Rightarrow$ Tổng số tokens = 12.

3.
$$P(w) = \frac{C(w)}{N}$$

$$\Rightarrow P(\text{the}) = \frac{C(\text{the})}{N} = \frac{3}{12} = 0.25$$

$$P(\text{cat}) = \frac{C(\text{cat})}{N} = \frac{2}{12}$$

$$P(\text{fish}) = \frac{C(\text{fish})}{N} = \frac{2}{12}$$

$$P(\text{dog}) = \frac{C(\text{dog})}{N} = \frac{1}{12}$$

$$4. P = \sum P(w) = \frac{3}{12} + \frac{2}{12} + \frac{2}{12} + \frac{1}{12} + \frac{1}{12} + \frac{1}{12} + \frac{1}{12} = 1$$

Bài 2: Bigram

$$P(w_t | w_{t-1}) = \frac{C(w_{t-1}, w_t)}{C(w_{t-1})}$$

$$P(\text{cat} | \text{the}) = \frac{C(\text{the}, \text{cat})}{C(\text{the})} = \frac{2}{3}$$

$$P(\text{dog} | \text{the}) = \frac{C(\text{the}, \text{dog})}{C(\text{the})} = \frac{1}{3}$$

$$P(\text{eat} | \text{cat}) = \frac{P(\text{cat}, \text{eat})}{P(\text{cat})} = \frac{1}{2}$$

$$P(\text{likes} | \text{cat}) = \frac{P(\text{cat}, \text{likes})}{P(\text{cat})} = \frac{1}{2}$$

Bài 3: Xác suất câu

Bigram: $P(\text{the}) P(\text{cat} | \text{the}) P(\text{eat} | \text{cat}) P(\text{fish} | \text{eat})$

$$P(\text{the}) = \frac{3}{12} = \frac{1}{4}$$

$$P(\text{cat} | \text{the}) = \frac{2}{3}$$

$$P(\text{eat} | \text{cat}) = \frac{1}{2}$$

$$P(\text{fish} | \text{eat}) = \frac{1}{2}$$

$$2) P(S) = \frac{1}{4} \cdot \frac{2}{3} \cdot \frac{1}{2} \cdot \frac{1}{2} = \frac{1}{24}$$

Nếu thêm 1 từ thì xác suất câu sẽ giảm hoặc giữ nguyên vì $0 \leq P(w) \leq 1$

Bài 4: Sentence Ranking

$$P(S_1) = \frac{1}{24}$$

$$\begin{aligned} P(S_2) &= P(\text{the}) \cdot P(\text{dog} | \text{the}) \cdot P(\text{eat} | \text{dog}) \cdot P(\text{fish} | \text{eat}) \\ &= \frac{1}{4} \cdot \frac{1}{3} \cdot 1 \cdot \frac{1}{2} = \frac{1}{24} \end{aligned}$$

$\Rightarrow$ 2 câu xếp ngang nhau

Bài tập quy luận trước Smoothing

1. Count của study AI

$$\text{count}(C(\text{study}, \text{AI})) = 0$$

2. Xác suất MLE

$$C(\text{study}) = 1$$

$$P(\text{AI} | \text{study}) = \frac{C(\text{study}, \text{AI})}{C(\text{study})} = \frac{0}{1} = 0$$

3. Xác suất câu = 0 vì có 1 thành phần $P = 0$

4. Không: Nó chỉ có nghĩa là câu đang chưa có trong corpus.

Bài tập Smoothing

$$P_{\text{Laplace}}(w|h) = \frac{C(h, w) + 1}{C(h) + V}$$

$$C(\text{cat} \& \text{eat}) = 0$$

$$\Rightarrow P(\text{eat} | \text{cat}) = \frac{1}{15}$$

$$C(\text{cat} | \text{eat}) = 3$$

$$\Rightarrow P(\text{eat} | \text{cat}) = \frac{3+1}{10+5} = \frac{4}{15}$$

$\Rightarrow$ Smoothing thêm 1 count giả cho mọi từ trong vocab.

Prediction trước experiment.

Prediction 1: Không đúng vì vocab là unique set trong corpus.

Prediction 2: Có xu hướng đúng

Prediction 3: Trigram vì cần quan sát context 2 từ trước đây

Prediction 4: Đại gram

Prediction 5: Không vì corpus nhỏ trigram sẽ không được quan sát.

Log probability

Vì sau phải dùng log probability

Vì với câu dài:

$$P(S) = p_1 \times p_2 \times p_3 \times \dots \times p_n$$

Mỗi xác suất < 1 nên nhân nhiều máy tính có thể làm tròn $= 0$

Log biến phép nhân thành phép cộng cái này log âm, chỉ để dễ học hơn

Bài tập tính perplexity

$$P(w_1) = 0,5$$

$$P(w_2 | w_1) = 0,25$$

$$P(w_3 | w_2) = 0,5$$

$$P(W) = 0,5 \cdot 0,25 \cdot 0,5 = \frac{1}{16}$$

$$PP(W) = P(W)^{(-1/N)} = \left(\frac{1}{16}\right)^{-\frac{1}{3}} \approx 2,52$$

$$\text{Nếu } P(w_2 | w_1) = 0,1$$

$$\rightarrow P(W) = 0,5 \cdot 0,1 \cdot 0,5 = 0,025$$

$$PP(W) = 0,025^{(-1/3)} \approx 3,42$$

Tóm tắt: Perplexity phụ thuộc vào các mức, và các mức này nhỏ hơn là $-\log(P)$ thì lớn.

Reflection:

Câu 1: Nếu tăng n , model nhận thông tin từ context phía trước. Model có thể dùng nhiều từ trước hơn để đoán từ tiếp theo.

Câu 2: Số combination có thể có của n -gram tăng rất nhanh khi n tăng, nếu vocab là từ điển gần có thể lên V^2, V^3 nếu bigram và trigram.

$\Rightarrow$ Trong corpus thực tế có ít combination từ quan sát $\Rightarrow$ tăng sparsity.

Câu 3: Vì $P(w | \text{context}) = 0$ với unseen n -gram

$\Rightarrow$ Smoothing giúp phân phối 1 phần probability mass cho từ hiện chưa quan sát, giúp model generalize tốt hơn sang dữ liệu mới.

Câu 4: Perplexity thường có nghĩa model gán probability cao hơn cho dữ liệu đã gặp, tuy nhiên chỉ dựa vào mức perplexity thì models dùng cùng data, quy trình ^{hiện} xử lý, cùng cách tính toán.

Câu 5:

Không nhất thiết vì perplexity gần các mức cho dữ liệu đã gặp, nó không trực tiếp đo các yếu tố con người quan tâm.

Câu 6:

N-gram chủ yếu dựa vào local token statistic
ví dụ tri-gram chỉ dựa 2 từ trước, nhưng context
có thể dài hơn

câu 7.

Kiểm tra, tri-gram chỉ dùng 2 từ trước nó để đoán